МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
КАФЕДРА ВЫЧИСЛИТЕЛЬНОЙ ТЕХНИКИ

ОТЧЁТ

по лабораторной работе №2
по дисциплине «Основы нейронных сетей»
Тема: РЕКУРЕНТНЫЕ СЕТИ

Студент гр. 3312	_____	Барченков П.А.
Студент гр. 3312	_____	Лебедев И.А.
Студент гр. 3312	_____	Шарапов И.Д.
Преподаватель	_____	Петруша П.Г.

Санкт-Петербург
2026

Содержание

ЦЕЛЬ РАБОТЫ 3

ОПИСАНИЕ ЗАДАНИЯ 3

ПОДГОТОВКА ДАННЫХ 3

СТРУКТУРА МОДЕЛЕЙ 4

АНАЛИЗ РЕЗУЛЬТАТОВ 5

ВЫВОДЫ 8

ПРИЛОЖЕНИЕ 8

ЦЕЛЬ РАБОТЫ

Построение и изучение рекуррентных нейронных сетей для прогнозирования временной последовательности.

ОПИСАНИЕ ЗАДАНИЯ

Самостоятельно выбрать датасет на сайте kaggle.com.

Подготовить (нормализовать) временной ряд.

Построить три архитектуры RNN (простую, LSTM, GRU).

Применить на всех 3 архитектурах функции потери:

- Стохастический градиентный спуск (SGD).
- Оптимизатор импульса (Momentum).
- Среднеквадратичное распространение (RMSProp).
- Адаптивная оценка момента (Adam)

Применить на всех 3 архитектурах регуляризацию:

- L1
- L2

Проанализировать метрики и графики моделей. Выбрать наиболее точную и с её помощью выполнить предсказание на тестовой выборке.

ПОДГОТОВКА ДАННЫХ

В качестве датасета был выбран *«Intelligent Manufacturing Dataset»* https://www.kaggle.com/datasets/ziya07/intelligent-manufacturing-dataset. Файл manufacturing_6G_dataset.csv содержит временных отсчётов с интервалом в 1 минуту, описывающих работу 50 различных станков в трёх режимах: Active, Idle, Maintenance.

Для построения прогностической модели были отобраны 8 числовых признаков, характеризующих физическое и сетевое состояние оборудования: Temperature_C – температура, Vibration_Hz – вибрация, Power_Consumption_kW – потребляемая мощность, Network_Latency_ms – сетевая задержка, Packet_Loss_% – процент потерь пакетов,

Quality_Control_Defect_Rate_% – доля брака, Production_Speed_units_per_hr – скорость производства, Error_Rate_% – частота ошибок.

В качестве целевой переменной выбран Predictive_Maintenance_Score – показатель, изменяющийся от 0 до 1 и отражающий вероятность скорого отказа или потребности в обслуживании.

Предобработка данных была выполнена в следующих направлениях:

- Пропуски в данных отсутствуют.
- Все признаки и целевая переменная были нормализованы с помощью MinMaxScaler в диапазон [0, 1] для устойчивой работы градиентных методов.
- Из нормализованного временного ряда сформированы обучающие последовательности методом скользящего окна (lookback = 10). Каждому моменту времени ставится в соответствие блок из 10 предыдущих измерений, по которому модель предсказывает целевое значение в следующий момент.
- Данные разделены на обучающую (80%) и тестовую (20%) выборки с сохранением временного порядка.

СТРУКТУРА МОДЕЛЕЙ

В рамках задания были построены три архитектуры рекуррентных нейронных сетей:

- SimpleRNN – базовая рекуррентная сеть,
- LSTM – сеть долгой краткосрочной памяти,
- GRU – управляемый рекуррентный блок.

Все модели имели одинаковую структуру:

- Один рекуррентный слой на 50 нейронов (функция активации tanh).
- Один полносвязный выходной слой с линейной активацией (предсказание одного числа).
- Функция потерь – среднеквадратичная ошибка (mse), дополнительная метрика – средняя абсолютная ошибка (mae).

Для каждой архитектуры были последовательно применены четыре оптимизатора:

- SGD (скорость обучения 0.01, без момента),
- Momentum (SGD с моментом 0.9),
- RMSProp (скорость обучения 0.001),
- Adam (скорость обучения 0.001).

Кроме того, для каждой архитектуры с оптимизатором Adam были проверены два вида регуляризации ядер рекуррентного слоя:

- L1 (коэффициент 0.001),
- L2 (коэффициент 0.001).

Каждая модель обучалась 20 эпох с размером батча 64 и валидационной выборкой 20% от обучающей.

АНАЛИЗ РЕЗУЛЬТАТОВ

На рисунке 1 представлены кривые обучения (MSE на обучающей выборке). Все модели демонстрируют быстрое снижение ошибки в первые эпохи, после чего выходят на плато.

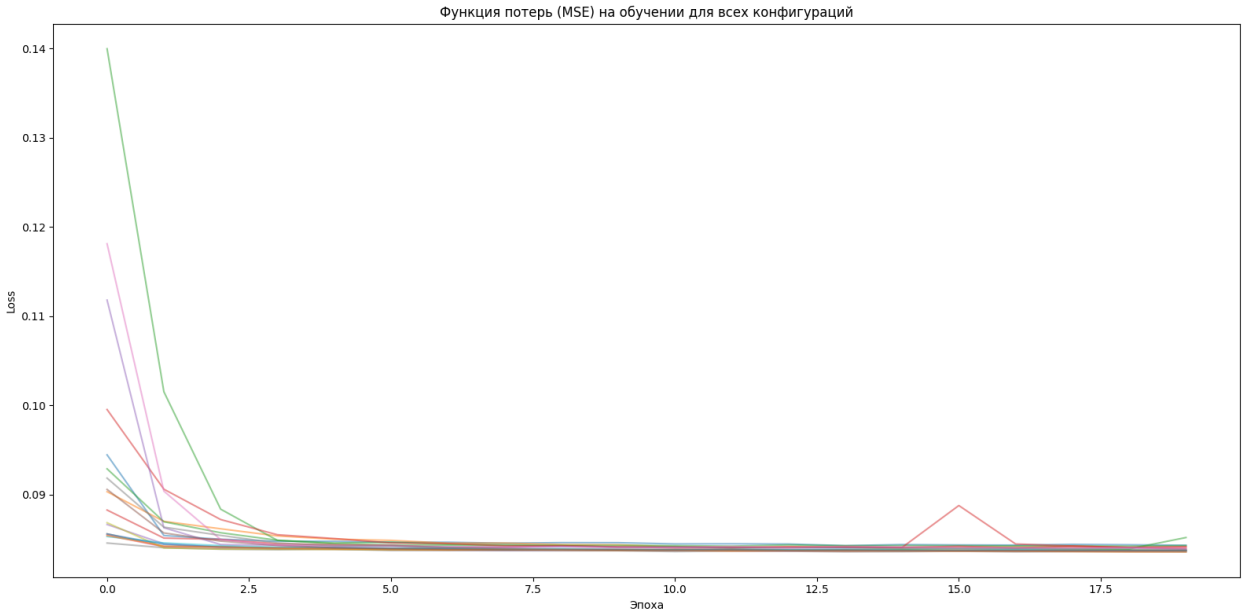

Рисунок 1 – Кривые обучения

Таблица 1

Сравнение MSE и MAE моделей

Архитектура	**Оптимизатор**	**Регуляризация**	**MSE**	**MAE**
SimpleRNN	sgd	None	0.084624	0.251319
SimpleRNN	momentum	None	0.083867	0.250606
SimpleRNN	rmsprop	None	0.084149	0.250931
SimpleRNN	adam	None	0.083792	0.250523
LSTM	sgd	None	0.083524	0.250285
LSTM	momentum	None	0.083693	0.250387
LSTM	rmsprop	None	0.083560	0.250279
LSTM	adam	None	0.083607	0.250343
GRU	sgd	None	0.083591	0.250299
GRU	momentum	None	0.083546	0.250284
GRU	rmsprop	None	0.083690	0.250410
GRU	adam	None	0.083686	0.250440
SimpleRNN	adam	L1	0.085374	0.252207
SimpleRNN	adam	L2	0.083556	0.250300
LSTM	adam	L1	0.083813	0.250583
LSTM	adam	L2	0.083501	0.250255
GRU	adam	L1	0.083514	0.250269
GRU	adam	L2	0.083546	0.250297

В таблице 1 приведены итоговые метрики MSE и MAE на тестовой выборке. Результаты всех моделей оказались очень близкими: MSE лежит в диапазоне 0.0835–0.0854, MAE – 0.250–0.252. Это свидетельствует о хорошей сходимости всех вариантов при выбранных гиперпараметрах.

Архитектуры LSTM и GRU в большинстве случаев немного превосходят SimpleRNN. Минимальное значение MSE (0.083501) достигнуто моделью LSTM с Adam и L2-регуляризацией.

Все оптимизаторы дают примерно равный результат, разница MSE редко превышает 0.001 (рис. 2).

Применение L2-регуляризации позволило незначительно улучшить обобщающую способность для LSTM и SimpleRNN, тогда как L1 на SimpleRNN привела к наибольшей ошибке (MSE = 0.085374, рис. 3).

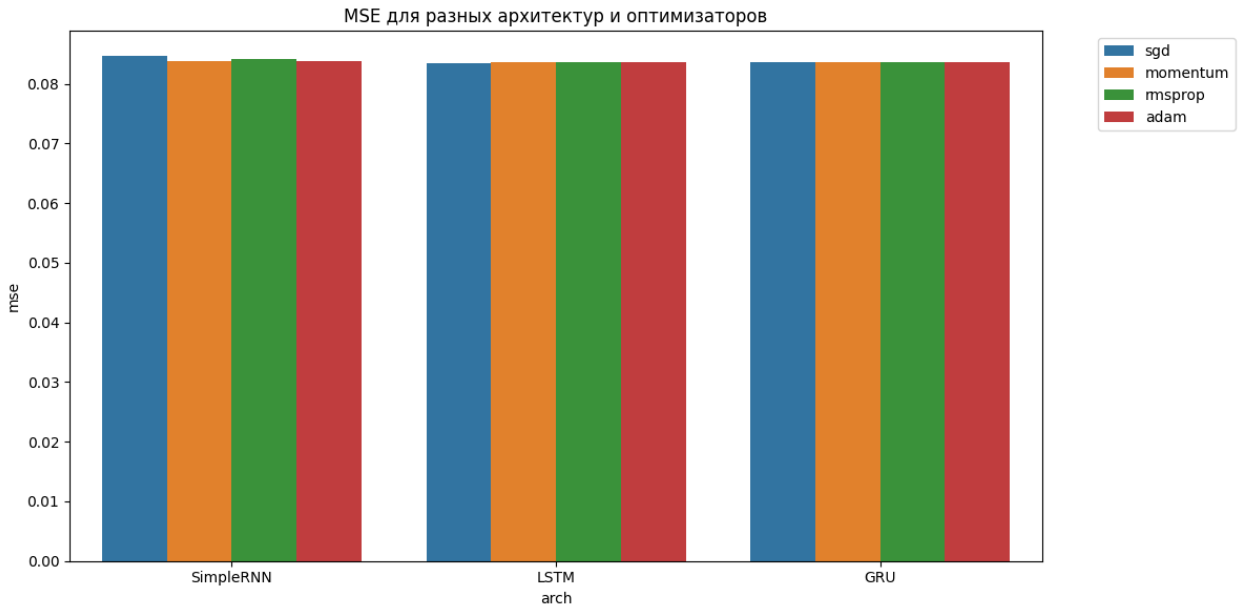

Рисунок 2 – Сравнение MSE по архитектурам и оптимизаторам

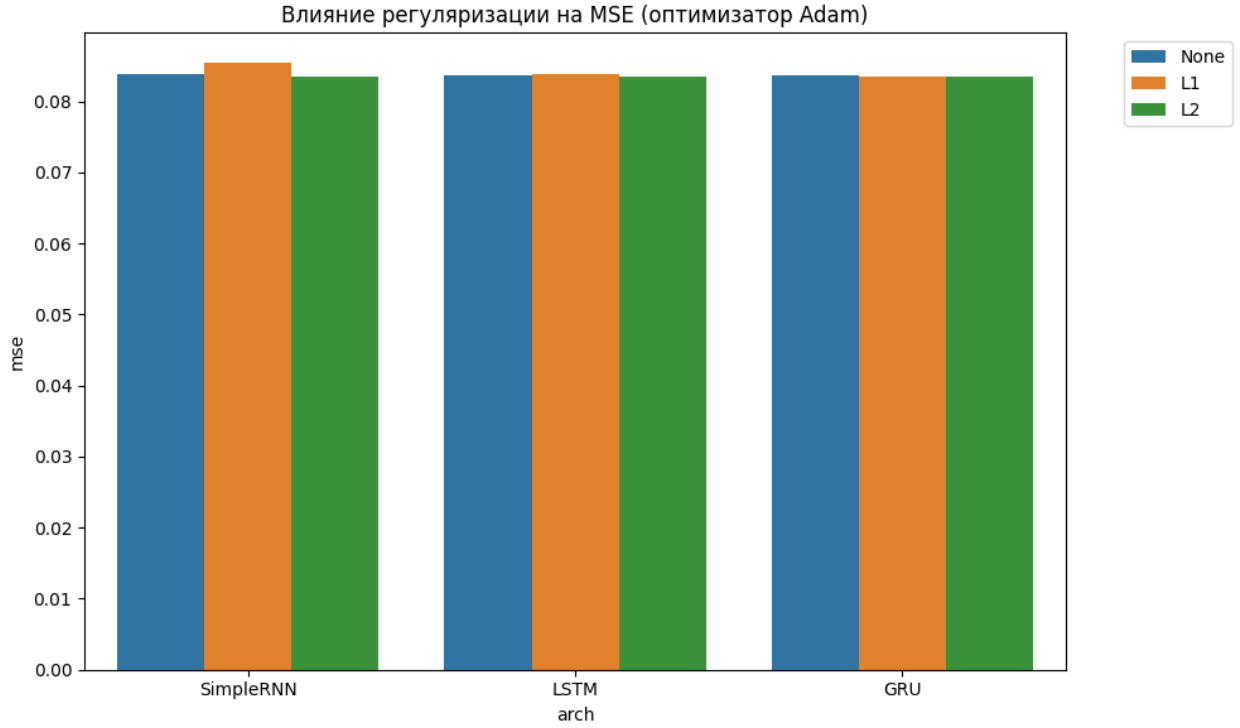

Рисунок 3 – Влияние регуляризации

На рисунке 4 продемонстрирован прогноз лучшей модели (LSTM_adam_L2) на фрагменте тестовой выборки.

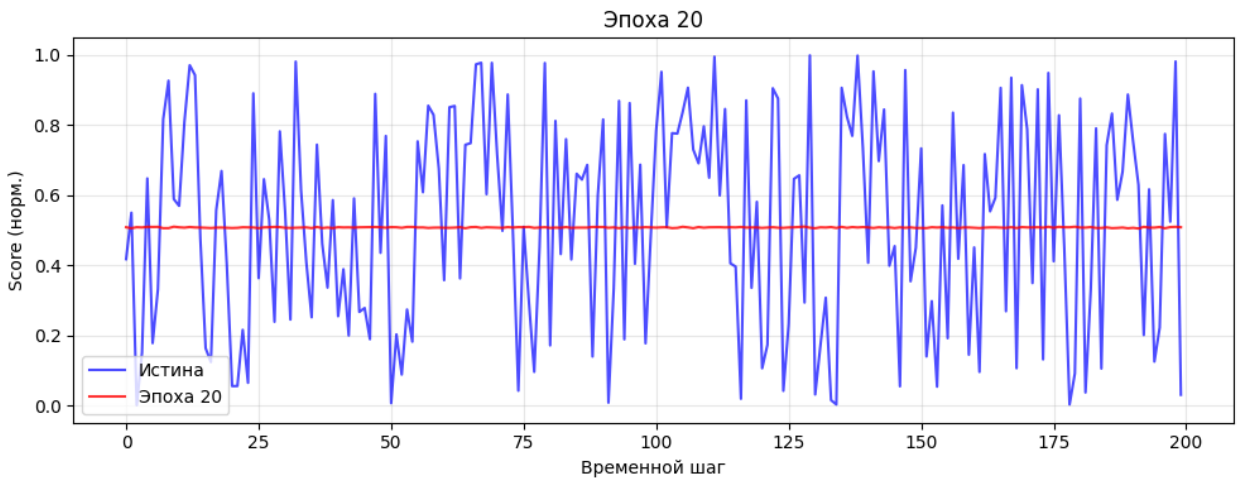

Рисунок 4 – Прогноз лучшей модели

ВЫВОДЫ

На основе набора данных «Intelligent Manufacturing Dataset» построены и обучены три типа рекуррентных нейронных сетей: SimpleRNN, LSTM и GRU. Наилучший результат достигнут моделью LSTM с оптимизатором Adam и L2-регуляризацией (MSE = 0.083501, MAE = 0.250255), что подтверждает эффективность LSTM для обработки временных последовательностей и целесообразность применения L2-регуляризации для небольшого дополнительного улучшения обобщения.

Влияние выбора оптимизатора оказалось незначительным. L1-регуляризация в данной задаче привела к ухудшению качества на SimpleRNN и практически не изменила результаты на LSTM/GRU; L2-регуляризация показала себя более стабильным инструментом.

Лабораторная работа позволила на практике сравнить различные конфигурации RNN, оценить влияние оптимизаторов и методов регуляризации, а также приобрести навыки предобработки временных рядов и интерпретации результатов обучения нейронных сетей.

ПРИЛОЖЕНИЕ

Ссылка на GitHub: https://github.com/DexTver/NN_LETI/tree/lab02