

**МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
КАФЕДРА ВЫЧИСЛИТЕЛЬНОЙ ТЕХНИКИ**

ОТЧЁТ
по лабораторной работе №3
по дисциплине «Основы нейронных сетей»
Тема: ГЕНЕРАТИВНЫЕ СЕТИ

Студент гр. 3312	_____	Барченков П.А.
Студент гр. 3312	_____	Лебедев И.А.
Студент гр. 3312	_____	Шарапов И.Д.
Преподаватель	_____	Петруша П.Г.

Санкт-Петербург
2026

Содержание

ЦЕЛЬ РАБОТЫ	3
ОПИСАНИЕ ЗАДАНИЯ	3
ПОДГОТОВКА ДАННЫХ.....	3
СТРУКТУРА МОДЕЛИ	4
АНАЛИЗ РЕЗУЛЬТАТОВ.....	5
ВЫВОДЫ	8
ПРИЛОЖЕНИЕ	9

ЦЕЛЬ РАБОТЫ

Изучение и реализация генеративной диффузионной модели (DDPM) для синтеза изображений по текстовому запросу с использованием условного U-Net и языковой модели для семантического сопоставления текста с классом обучающего датасета.

ОПИСАНИЕ ЗАДАНИЯ

В рамках лабораторной работы требовалось выполнить следующий набор шагов:

1. Самостоятельно выбрать датасет изображений с осмысленными метками классов.
2. Реализовать прямой диффузионный процесс – постепенное добавление гауссовского шума к исходным изображениям по фиксированному расписанию β .
3. Построить нейросеть-шумоподаватель на основе архитектуры U-Net с обусловливанием по временному шагу и по метке класса.
4. Обучить модель восстанавливать добавленный шум, минимизируя MSE между предсказанным и истинным шумом.
5. Подключить языковую модель (LLM) для перевода произвольного текстового запроса в наиболее подходящий класс из обучающего датасета.
6. Реализовать обратный диффузионный процесс и сгенерировать изображения по нескольким текстовым описаниям.

ПОДГОТОВКА ДАННЫХ

В качестве датасета был выбран CIFAR-100, загружаемый через библиотеку datasets от HuggingFace. Датасет содержит 50000 обучающих изображений размером 32×32 пикселя, размеченных по 100 осмысленным классам (например, apple, tiger, rose, skyscraper, bicycle). Наличие большого числа классов с понятными названиями принципиально важно для второго

этапа работы – сопоставления свободного текстового запроса с одним из классов обучающей выборки.

Увеличено число шагов диффузии до 1000 (в примере было 100), что даёт более плавный прямой процесс и более качественную генерацию.

СТРУКТУРА МОДЕЛИ

Решение состоит из трёх связанных компонентов: модели прямого/обратного диффузионного процесса DenoiseDiffusion, обусловленной нейросети-шумоподавителя UNet и языковой модели для маппинга текста в класс.

Прямой процесс задан расписанием β линейного типа в диапазоне $[0.0001, 0.02]$ на 1000 шагов. Соответствующая визуализация прямого процесса (рис. 2) подтверждает, что к 1000-му шагу исходное изображение полностью переходит в гауссовский шум.

Архитектура U-Net реализована по образцу и расширена обусловливанием по классу. По сравнению с базовой реализацией внесены два изменения:

- в конструктор добавлен модуль `self.class_emb` – обучаемый эмбединг класса той же размерности, что и временной эмбединг;
- в методе `forward` подпись расширена до (x, t, y) , а эмбединг класса складывается с временным эмбедингом перед прохождением через сеть.

Гиперпараметры U-Net: `image_channels=3`, `n_channels=32`, `ch_mults=(1, 2, 2)`, `is_attn=(False, True, True)`, `n_blocks=2`, `num_classes=100`. В качестве функции активации используется Swish, нормализация – GroupNorm, в средних и глубоких слоях применяются self-attention блоки. Общее число обучаемых параметров – около 3,52 млн.

Обучение проводилось 10 эпох оптимизатором AdamW с learning rate $2 \cdot 10^{-4}$ и обрезкой нормы градиента до 1.0. На каждом шаге случайно выбирается $t \sim U(0, 1000)$, для образца строится x_t , и сеть учится

предсказывать добавленный шум ϵ по входу (x_t, t, y) ; функция потерь – MSE между истинным и предсказанным шумом.

Для перевода текстового запроса в класс CIFAR-100 используется языковая модель SentenceTransformer all-MiniLM-L6-v2. Для каждого класса формируется промпт вида «a photo of a {class_name}», который кодируется в нормированный эмбединг. Пользовательский запрос кодируется тем же энкодером, после чего выбирается ближайший класс. Полученный индекс класса подаётся в обусловленный U-Net как метка y при обратном процессе сэмплирования.

АНАЛИЗ РЕЗУЛЬТАТОВ

На рисунке 1 показан фрагмент исходного датасета CIFAR-100 – изображения размера 32×32 пикселя из различных классов, на которых обучается модель.




Рисунок 1 – Примеры исходных изображений CIFAR-100

На рисунке 2 продемонстрирован прямой диффузионный процесс: одно и то же изображение показано на шагах $t = 0, 100, 300, 500, 800$ и 999. По мере роста t содержательная структура постепенно теряется, и на последнем шаге результат визуально неотличим от гауссовского шума, что соответствует теоретическим свойствам выбранного расписания β .




Рисунок 2 – Прямой процесс диффузии (зашумление по шагам)

В таблице 1 приведены средние значения функции потерь по эпохам обучения. Видно монотонное снижение MSE: с 0,1518 в первой эпохе до 0,0366 в десятой; основное падение приходится на первые две эпохи, после чего динамика выходит на пологое снижение, что характерно для DDPM с фиксированным расписанием шума.

Таблица 1

Среднее значение функции потерь по эпохам обучения

Эпоха	Средняя MSE
1	0.1518
2	0.0634
3	0.0523
4	0.0469
5	0.0442
6	0.0413
7	0.0395
8	0.0394
9	0.0379
10	0.0366

После завершения обучения была проверена работа сэмплирования: безусловно фиксированному классу apple был сгенерирован батч из восьми изображений (рис. 3). При относительно небольшом числе эпох и компактной модели в 3,52 млн параметров на выходе получаются узнаваемые цветовые пятна и общая форма объектов, характерные для класса; ожидать фотореалистичной детализации на CIFAR-100 при таких параметрах не приходится.




Рисунок 3 – Генерация для класса «apple»

Для оценки качества языковой модели было выполнено сопоставление пяти контрольных текстовых запросов с топ-3 ближайшими классами CIFAR-100 (табл. 2). LLM устойчиво распознаёт смысл запросов: «striped jungle predator» отображается в tiger, «tall building in the city» – в skyscraper,

«red juicy fruit» – в подходящие классы фруктов. Для каждого запроса первая позиция top-1 является семантически осмысленной.

Таблица 2

Сопоставление текстовых запросов с классами через LLM (top-3)

Запрос	Топ-3 классов CIFAR-100 (с косинусной близостью)
fluffy orange cat	orange (0.50), hamster (0.36), leopard (0.34)
striped jungle predator	tiger (0.46), lion (0.39), snake (0.37)
red juicy fruit	orange (0.43), pear (0.43), apple (0.37)
tall building in the city	skyscraper (top-1)
something to ride on the road	road / motorcycle / bicycle

Полноценная связка «текст → класс → диффузионная генерация» проверена на трёх запросах. Для запроса «a beautiful red flower in the garden» LLM выбрала класс rose (0,503; альтернативы – sunflower, orchid), и обусловленный U-Net сгенерировал восемь изображений соответствующего класса (рис. 4).




Рисунок 4 – Генерация по запросу «a beautiful red flower in the garden»

Для запроса «big striped wild cat from the jungle» был выбран класс tiger (0,482; альтернативы – lion, leopard), результаты генерации представлены на рисунке 5.



Рисунок 5 – Генерация по запросу «big striped wild cat from the jungle»

Для запроса «vehicle with two wheels you ride» LLM выбрала класс bicycle (0,414; альтернативы – road, motorcycle), что также семантически корректно; соответствующая генерация – на рисунке 6.




Рисунок 6 – Генерация по запросу «vehicle with two wheels you ride»

Во всех трёх случаях LLM-компонент корректно определил подходящий класс по неоднозначному описанию, а обусловленная диффузионная модель сгенерировала изображения, соответствующие этому классу – это подтверждает, что обусловливание по эмбедингу класса было успешно встроено в U-Net и используется при сэмплировании.

ВЫВОДЫ

В ходе лабораторной работы была реализована полная конвейерная связка для текстово-обусловленной генерации изображений на основе модели DDPM. В качестве обучающей выборки использовался CIFAR-100, содержащий 50000 изображений 32×32 пикселя в 100 классах с осмысленными метками. Прямой процесс описан линейным расписанием β на 1000 шагов; обратный процесс реализован сетью U-Net (около 3,52 млн параметров), дополнительно обусловленной по метке класса через обучаемый эмбединг той же размерности, что и временной эмбединг.

Обучение в течение 10 эпох оптимизатором AdamW показало устойчивое монотонное снижение средней MSE-ошибки с 0,1518 до 0,0366, что свидетельствует о корректной работе как самой архитектуры, так и схемы добавления и предсказания шума. Визуализация прямого процесса подтверждает корректное полное зашумление исходных изображений к концу расписания, а обратный процесс на обученной модели даёт визуально осмысленные образцы для заданных классов.

Подключение языковой модели SentenceTransformer all-MiniLM-L6-v2 позволило сопоставлять свободные текстовые запросы с одним из 100 классов CIFAR-100. На контрольных примерах LLM устойчиво выдавала семантически корректный top-1 класс, и обусловленная диффузионная модель

генерировала изображения этого класса, демонстрируя согласованную работу
обоих компонентов системы.

ПРИЛОЖЕНИЕ

Ссылка на GitHub: https://github.com/DexTver/NN_LETI/tree/lab03